# Documentacion Etapa IV - Analisis

#### Emiliano Garcia

2025-08-12

# Etapa IV - Analisis

```
library(tidyverse)
library(corrplot)
master_table_clean <- read_csv ("master_table_clean.csv")</pre>
```

#### Previsualizacion de los datos

## \$ ActivityDate
## \$ TotalSteps

## \$ TotalDistance

```
head (master_table_clean)
## # A tibble: 6 x 8
             Id ActivityDate
                               TotalSteps TotalDistance Calories TotalMinutesAsleep
##
                                                   <dbl>
                                                            <dbl>
                                                                                <dbl>
          <dbl> <chr>
                                     <dbl>
## 1 1503960366 2016-03-25 00~
                                    11004
                                                   7.11
                                                             1819
                                                                                   NA
## 2 1503960366 2016-03-26 00~
                                                                                   NA
                                                   11.6
                                                             2154
                                    17609
## 3 1503960366 2016-03-27 00~
                                    12736
                                                    8.53
                                                             1944
                                                                                   NA
## 4 1503960366 2016-03-28 00~
                                    13231
                                                    8.93
                                                             1932
                                                                                   NA
## 5 1503960366 2016-03-29 00~
                                    12041
                                                    7.85
                                                             1886
                                                                                   NA
## 6 1503960366 2016-03-30 00~
                                                                                   NA
                                    10970
                                                    7.16
                                                             1820
## # i 2 more variables: WeightKg <dbl>, SourcePeriod <chr>
colnames (master_table_clean)
## [1] "Id"
                             "ActivityDate"
                                                  "TotalSteps"
## [4] "TotalDistance"
                            "Calories"
                                                  "TotalMinutesAsleep"
## [7] "WeightKg"
                            "SourcePeriod"
str (master_table_clean)
## spc_tbl_ [1,373 x 8] (S3: spec_tbl_df/tbl_df/tbl/data.frame)
## $ Id
                        : num [1:1373] 1.5e+09 1.5e+09 1.5e+09 1.5e+09 1.5e+09 ...
```

```
1
```

: num [1:1373] 1819 2154 1944 1932 1886 ...

: num [1:1373] 11004 17609 12736 13231 12041 ... : num [1:1373] 7.11 11.55 8.53 8.93 7.85 ...

: chr [1:1373] "2016-03-25 00:00:00.000000 UTC" "2016-03-26 00:00:00.000000 UTC

```
## $ WeightKg
                      : num [1:1373] NA ...
                       : chr [1:1373] "03-04" "03-04" "03-04" "03-04" ...
##
   $ SourcePeriod
##
   - attr(*, "spec")=
##
    .. cols(
##
         Id = col_double(),
##
         ActivityDate = col_character(),
       TotalSteps = col double(),
##
##
         TotalDistance = col_double(),
##
    .. Calories = col_double(),
##
    .. TotalMinutesAsleep = col_double(),
    .. WeightKg = col_double(),
         SourcePeriod = col_character()
##
##
    ..)
   - attr(*, "problems")=<externalptr>
summary (master_table_clean)
                       ActivityDate
                                                        TotalDistance
##
         Ιd
                                           TotalSteps
                                         Min. : 0
##
          :1.504e+09
                      Length: 1373
                                                        Min. : 0.000
  \mathtt{Min}.
## 1st Qu.:2.320e+09
                      Class :character
                                         1st Qu.: 3325
                                                        1st Qu.: 2.290
## Median :4.445e+09
                      Mode :character
                                         Median : 7142
                                                        Median : 5.030
## Mean :4.782e+09
                                         Mean : 7465
                                                        Mean : 5.356
## 3rd Qu.:6.962e+09
                                         3rd Qu.:10688
                                                        3rd Qu.: 7.630
## Max. :8.878e+09
                                         Max. :51072
                                                        Max.
                                                              :44.360
##
##
      Calories
                  TotalMinutesAsleep
                                       WeightKg
                                                     SourcePeriod
## Min. : 0
                  Min. : 58.0
                                    Min.
                                          : 52.60
                                                     Length: 1373
##
  1st Qu.:1820
                 1st Qu.: 364.5
                                    1st Qu.: 61.50
                                                     Class :character
## Median :2138
                 Median : 436.5
                                    Median : 62.50
                                                    Mode :character
## Mean :2319
                  Mean : 437.3
                                    Mean : 72.47
                  3rd Qu.: 499.0
## 3rd Qu.:2786
                                    3rd Qu.: 85.25
                                    Max. :133.50
## Max. :9718
                  Max. :1500.0
##
                  NA's
                         :963
                                    NA's :1275
```

## Estadisticas descriptivas – Media, Mediana y Desvio estandar

Tabla de medias por usuario

```
mean_users <- master_table_clean %>%
  group_by (Id) %>%
  summarise (
    mean_steps = mean (TotalSteps),
    mean_distance = mean (TotalDistance),
    mean_calories = mean (Calories)
  )
View (mean_users)
```

Tabla de medianas por usuario

```
median_users <- master_table_clean %>%
  group_by (Id) %>%
  summarise (
    median_steps = median (TotalSteps),
    median_distance = median (TotalDistance),
    median_calories = median (Calories)
  )
View (median_users)
```

#### Tabla de desvios por usuario

```
sd_users <- master_table_clean %>%
  group_by (Id) %>%
  summarise (
    sd_steps = sd (TotalSteps),
    sd_distance = sd (TotalDistance),
    sd_calories = sd (Calories)
  )
View (sd_users)
```


## Graficos para entender distribuciones de datos.

Todas son sesgadas a la derecha, es decir, concentran la mayor cantidad de datos a la izquierda

## Grafico I. Distribucion de pasos diarios

```
ggplot (data = master_table_clean) +
  geom_histogram (mapping = aes (x = TotalSteps), fill = "green") +
  labs (title = "Distribucion de pasos diarios")
```

# Distribucion de pasos diarios



## Grafico II. Distribucion de calorias diarias

```
ggplot (data = master_table_clean) +
  geom_histogram (mapping = aes (x = Calories), fill = "orange") +
  labs (title = "Distribucion de calorias diarias")
```

# Distribucion de calorias diarias





Grafico III. Distribucion de la distancia total recorrida

```
ggplot (data = master_table_clean) +
  geom_histogram (mapping = aes (x = TotalDistance), fill = "blue") +
  labs (title = "Distribucion de distancia diaria recorrida")
```

# Distribucion de distancia diaria recorrida



# Graficos para relacionar variables

## Matriz de correlaciones

```
var_table <- master_table_clean %>%
  dplyr::select ("TotalSteps", "TotalDistance", "Calories")


cor_matriz <- cor (var_table, use = "complete.obs")
corrplot (cor_matriz, method = "number", type = "upper")</pre>
```



## Grafico IV. Correlaciones

```
ggplot (data = master_table_clean, aes (x = TotalSteps, y = Calories)) +
geom_point (color = "darkgreen") +
geom_smooth (method = "lm", color = "red") +
labs (title = "Relacion pasos-calorias")
```

# Relacion pasos-calorias




## Agrupamos usuarios por nivel de actividad

Tabla segun nivel de actividad

```
activity_table <- master_table_clean %>%
  group_by (Id) %>%
  summarise (mean_steps = mean (TotalSteps)) %>%
  mutate (activity_level = case_when (
    mean_steps < 5000 ~ "Baja",
    mean_steps < 10000 ~ "Moderada",
    TRUE ~ "Alta"
))</pre>
```

#### Grafico V. Usuarios por nivel de actividad

# Usuarios por nivel de actividad



# Actividad segun dia de la semana


Convertimos ActivityDate a formato fecha

```
master_table_clean <- master_table_clean %>%
  mutate (ActivityDate = as.Date(ActivityDate))
```

#### Tabla segun dias

#### Grafico VI. Promedio de pasos por dia de la semana

## Promedio de pasos por dia de la semana




# Promedio diario de pasos por usuario, en general, y su evolucion temporal Tabla

```
daily_trend <- master_table_clean %>%
  group_by (ActivityDate) %>%
  summarise (avg_steps = mean (TotalSteps))
```

El dia con menos pasos totales realizados por los 35 usuarios en su conjunto fue el 2016-03-18, con tan solo 658 pasos registrados por cada uno de ellos, en promedio. Por su parte, El dia con mas pasos totales realizados por el conjunto de usuarios que compartieron sus datos fue el 2016-04-12 con 10.780 para cada uno de ellos, en promedio.


#### Grafico VII. Tendencia temporal del promedio diario de pasos

# Tendencia del promedio diario de pasos



## Grafico VIII. Analisis relacion distancia - calorias

## Relacion distancia - calorias



#### Nivel de actividad - dias de la semana


Tabla que distingue dentro de cada dia la cantidad de pasos promedio que realiza cada grupo de actividad

#### Grafico IX. Promedio de pasos al dia segun nivel de actividad

```
ggplot (data = activity_weekday, aes (x = weekday, y = avg_steps, fill = activity_level)) +
geom_col () +
facet_wrap (~ activity_level) +
theme (axis.text.x = element_text(angle = 90)) +
labs (title = "Promedio de pasos por dia y nivel de actividad",
```

```
x = "Dias de la semana",
y = "Pasos promedio")
```

# Promedio de pasos por dia y nivel de actividad




## Activity\_level vs Calories

Tabla de la relacion entre nivel de actividad y calorias gastadas

```
calories_activity <- master_table_clean %>%
  group_by(Id) %>%
  summarise(
    mean_steps = mean (TotalSteps),
    mean_calories = mean (Calories)) %>%
  mutate (activity_level = case_when (
    mean_steps < 5000 ~ "Baja",
    mean_steps < 10000 ~ "Moderada",
    TRUE ~ "Alta"
))</pre>
```

Grafico X. Consumo calorico promedio segun nivel de actividad

# Consumo calorico promedio segun nivel de actividad



## Reconocimiento de perfiles extremos (5 mas y menos activos)

#### Pasos y calorias por usuario

```
user_calories_activity <- master_table_clean %>%
  group_by(Id) %>%
  summarise(
  mean_steps = mean (TotalSteps),
  mean_calories = mean (Calories),
  active_days = n ())
```

#### Top 5 mas activos

```
top5 <- user_calories_activity %>%
arrange (desc(mean_steps)) %>%
```

```
slice (1:5) %>%
mutate (group = "Top 5 activos")
```

## Top 5 menos activos

```
bottom5 <- user_calories_activity %>%
  arrange (mean_steps) %>%
  slice (1:5) %>%
  mutate (group = "Top 5 menos activos")
```

#### Grafico XI. Comparacion de perfiles extremos

# Top 5 vs Bottom 5 usuarios

